Министерство образования Республики Беларусь

Учреждение образования

«БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ»

Факультет компьютерных систем и сетей

Кафедра программного обеспечения информационных технологий

Дисциплина: Методы машинного обучения (ММО)

ОТЧЕТ

по лабораторной работе № 3

Тема работы: Градиентный спуск, стохастический градиентный спуск и регуляризация

Выполнил:

студент гр. 351002 Алексейчик Я. Н.

Проверил: Лебедевич А. В.

Минск 2026

1 ЦЕЛЬ РАБОТЫ

Изучение математических основ и практическая программная реализация методов оптимизации функционалов качества в задачах линейной регрессии:

1. Реализация алгоритма пакетного градиентного спуска (Batch Gradient Descent) с векторным расчетом градиентов и критерием останова по евклидовой норме изменения весов $\|w^k - w^{k-1}\|_2 < \varepsilon$;
2. Экспериментальное исследование влияния шага обучения (Learning Rate η) на скорость сходимости и устойчивость алгоритма;
3. Реализация стохастического градиентного спуска (Stochastic Gradient Descent) со случайным выбором объектов и расписанием затухания темпа обучения Роббинса-Монро;
4. Сравнительный анализ скорости сходимости GD и SGD на одном графическом поле;
5. Реализация L_1-регуляризации (Lasso) для четного варианта 2 через проксимальный оператор Soft-Thresholding (ISTA), а также L_2-регуляризации (Ridge) для 20 значений параметра λ в диапазоне от 0.001 до 1000;
6. Сравнение полученных параметров с библиотечными реализациями Scikit-Learn.

2 ОПИСАНИЕ НАБОРА ДАННЫХ И ПРЕДВАРИТЕЛЬНАЯ ОБРАБОТКА

В качестве предметной базы использован набор данных из Лабораторной работы №2 (`StudentPerformanceFactors.csv`, $N = 6607$ наблюдений).

Для выполнения условия задания «не менее 2 признаков без учета целевого (не менее 3 весов)» сформирован набор из $m = 6$ физически интерпретируемых признаков, что с учетом фиктивного единичного столбца для свободного члена w_0 образует вектор из 7 весовых параметров:

- `Hours_Studied` — количество часов самостоятельных занятий в неделю;
- `Attendance` — посещаемость учебных занятий (%);
- `Previous_Scores` — результаты предварительного тестирования;

- Tutoring_Sessions — число индивидуальных занятий с репетитором;
- Physical_Activity — часы физической культуры и спорта;
- Parental_Involvement — степень вовлеченности родителей в образовательный процесс.

Целевая переменная: Exam_Score — итоговая экзаменационная оценка студента (баллы от 0 до 100).

Предотвращение утечки данных (Data Leakage): Масштабирование признаков алгоритмом StandardScaler ($z = \frac{x-\mu}{\sigma}$) обучено строго на обучающей подвыборке (80%, $N_{train} = 5285$), после чего применилось к тестовой подвыборке (20%, $N_{test} = 1322$). Признак Score_Improvement исключен, так как он содержит целевую переменную.

3 МАТЕМАТИЧЕСКИЕ ОСНОВЫ АЛГОРИТМОВ ОПТИМИЗАЦИИ

3.1 Пакетный градиентный спуск (BGD)

Функция потерь среднеквадратичной ошибки (MSE):

$$Q(w) = \frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2 = \frac{1}{n}\|X_b w - y\|_2^2 \tag{1}$$

Векторный градиент по весам $w \in \mathbb{R}^{m+1}$:

$$\nabla Q(w) = \frac{2}{n}X_b^T(X_b w - y) \tag{2}$$

Правило обновления весов:

$$w^k = w^{k-1} - \eta \cdot \frac{2}{n}X_b^T(X_b w^{k-1} - y) \tag{3}$$

Критерий останова итерационного процесса:

$$\|w^k - w^{k-1}\|_2 = \sqrt{\sum_{j=0}^{m}(w_j^k - w_j^{k-1})^2} < \varepsilon = 10^{-6} \tag{4}$$

3.2 Стохастический градиентный спуск (SGD)

На шаге k выбирается случайный индекс объекта $i \in \{0, \ldots, n-1\}$. Стохастический градиент:

$$\nabla q_i(w^{k-1}) = 2(x_i^T w^{k-1} - y_i)x_i \tag{5}$$

Расписание скорости обучения для гарантированной сходимости по условию Роббинса-Монро ($\sum \eta_k = \infty, \sum \eta_k^2 < \infty$):

$$\eta_k = \frac{\eta_0}{1 + \alpha \cdot k}, \quad \eta_0 = 0.01, \quad \alpha = 0.0001 \tag{6}$$

3.3 L1-регуляризация (Lasso, Вариант 2)

Минимизируемый функционал (смещение w_0 не штрафуется):

$$Q_{L1}(w) = \frac{1}{n}\|X_b w - y\|_2^2 + \lambda \sum_{j=1}^{m} |w_j| \tag{7}$$

Проксимальный шаг Soft-Thresholding (ISTA):

$$\tilde{w} = w^{k-1} - \eta \nabla Q(w^{k-1}) \tag{8}$$

$$w_0^k = \tilde{w}_0, \quad w_j^k = \text{sign}(\tilde{w}_j) \cdot \max(0, |\tilde{w}_j| - \eta\lambda), \quad j = 1, \ldots, m \tag{9}$$

3.4 L2-регуляризация (Ridge)

$$Q_{L2}(w) = \frac{1}{n}\|X_b w - y\|_2^2 + \lambda \sum_{j=1}^{m} w_j^2 \tag{10}$$

Безусловно устойчивый оператор сжатия весов (Weight Decay):

$$w_0^k = w_0^{k-1} - \eta \nabla Q_0, \quad w_j^k = \frac{w_j^{k-1} - \eta \nabla Q_j}{1 + 2\eta\lambda}, \quad j = 1, \ldots, m \tag{11}$$

4 РЕЗУЛЬТАТЫ ЭКСПЕРИМЕНТОВ

4.1 Эксперимент 1: Исследование скорости обучения η

В таблице 1 представлены характеристики сходимости BGD при различных η.

Таблица 1 — Влияние темпа обучения η на сходимость градиентного спуска

Темп η	**Итераций**	**Сходимость**	**Test MSE**	**Test R^2**	**Время (мс)**
0.0005	3000	Нет (лимит)	13.4522	-0.1933	146.11
0.0050	1337	Да	1.9954	0.8230	61.29
0.0200	364	Да	1.9954	0.8230	16.57
0.0500	151	Да	1.9954	0.8230	7.16
0.1000	75	Да	1.9954	0.8230	3.52
0.2500	**27**	**Да**	**1.9954**	**0.8230**	**1.35**

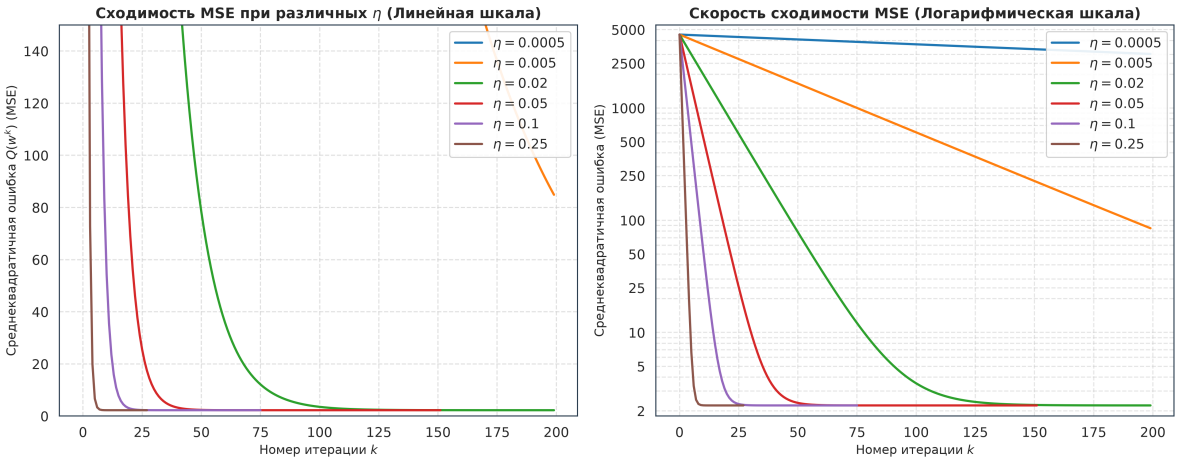


Рисунок 1 — Динамика сходимости MSE при различных скоростях обучения η

4.2 Эксперимент 2: Сравнение пакетного (GD) и стохастического (SGD) спуска

Таблица 2 — Сравнительные показатели BGD и SGD

Алгоритм	Размер пакета	Шагов	Test MSE	Test R^2	Сложность 1
BGD	$N = 5285$ (вся выборка)	151	1.9954	0.8230	$\mathcal{O}(N \cdot m$
SGD	1 случайный объект	10000	2.1306	0.8110	$\mathcal{O}(m)$

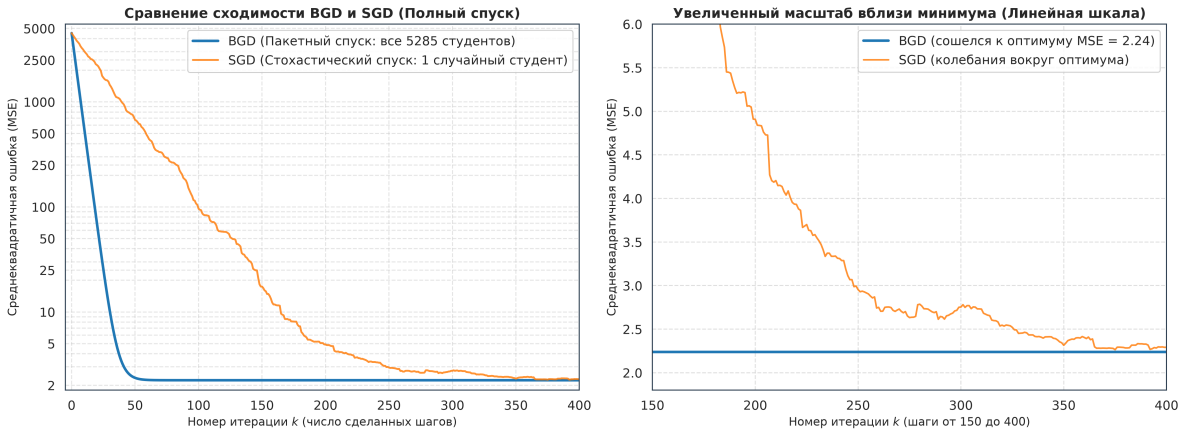


Рисунок 2 — Сравнение сходимости GD и SGD на едином графическом поле

4.3 Эксперимент 3: Регуляризационные пути (L1 для варианта 2 и L2)

Исследовано 20 значений $\lambda \in [10^{-3}, 10^{3}]$. На рисунках 3 и 4 приведены пути изменения весовых параметров.

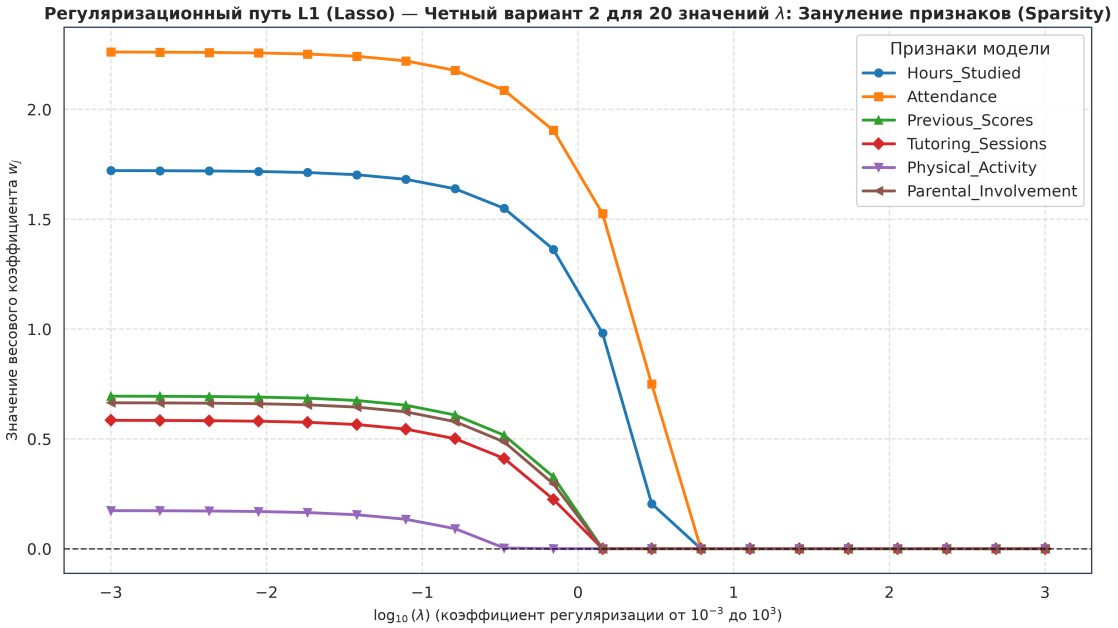


Рисунок 3 — Регуляризационный путь L1 (Lasso) для четного варианта 2: зануление признаков (Sparsity)

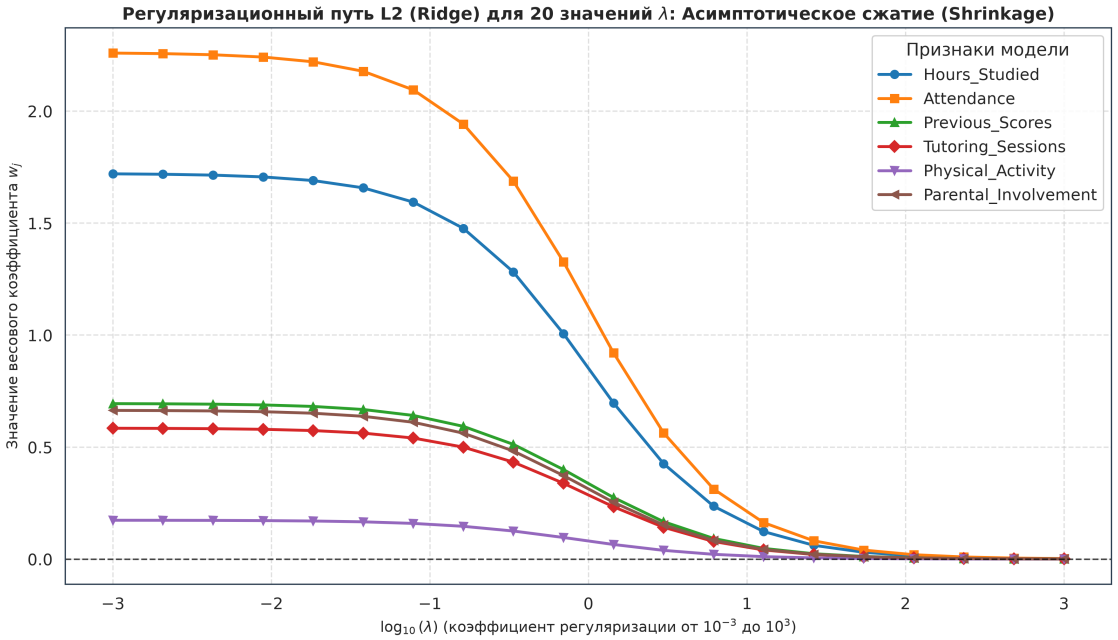


Рисунок 4 — Регуляризационный путь L2 (Ridge): непрерывное сжатие весов к нулю (Shrinkage)

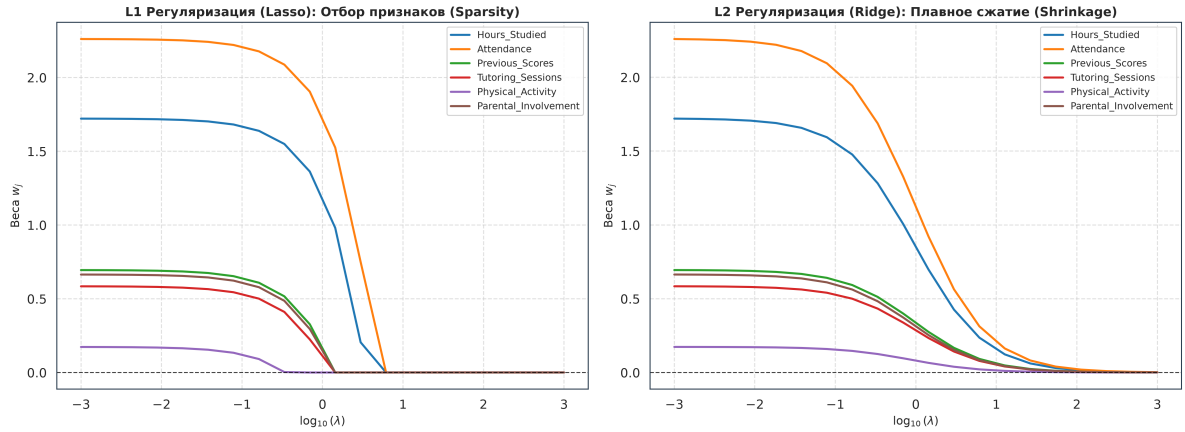


Рисунок 5 — Сопоставление отбора признаков (L1) и сжатия коэффициентов (L2)

4.4 Эксперимент 4: Сравнение с библиотекой Scikit-Learn

Таблица 3 — Результаты эталонного тестирования против Scikit-Learn

Модель	**Intercept** w_0	$\|w\|_2$	**Test MSE**	**Test MAE**	**Test** R^2
Custom BGD	67.0982	3.0620	1.9954	1.0444	0.8230
Sklearn OLS	67.0982	3.0620	1.9954	1.0444	0.8230
Custom SGD	67.2268	2.8703	2.1306	1.0951	0.8110
Sklearn SGD	67.1103	3.0535	1.9923	1.0436	0.8233
Custom L1 ($\lambda = 0.5$)	67.0982	2.5707	2.3515	1.1603	0.7914
Sklearn Lasso ($\alpha = 0.25$)	67.0982	2.5707	2.3515	1.1603	0.7914
Custom L2 ($\lambda = 1.0$)	67.0982	1.5129	4.3653	1.6541	0.6128
Sklearn Ridge ($\alpha = 5285.0$)	67.0982	1.5129	4.3653	1.6541	0.6128

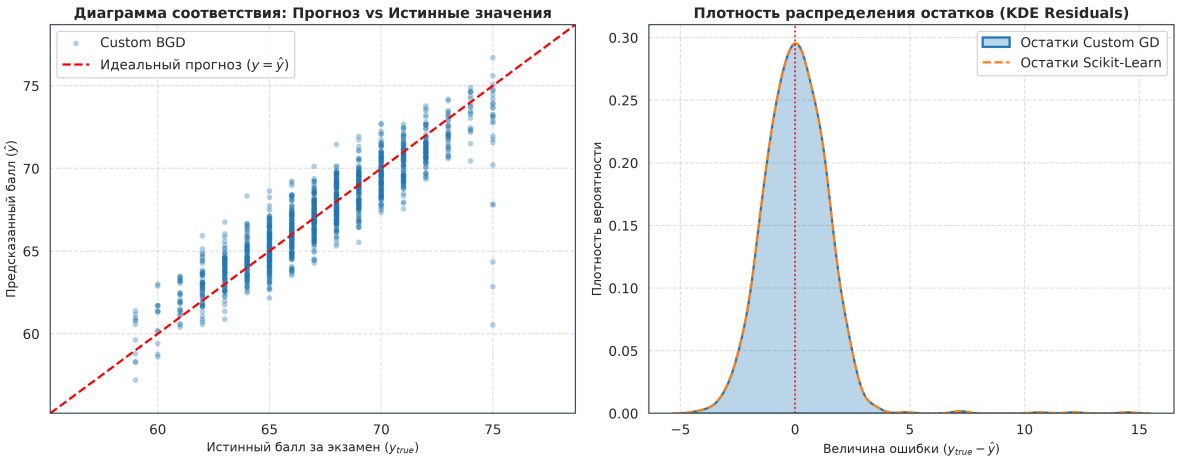


Рисунок 6 — Диаграмма рассеяния «Прогноз vs Факт» и плотность распределения остатков

5 ВЫВОДЫ

1. Реализован полностью векторизованный модуль линейной регрессии на базе градиентных методов оптимизации, демонстрирующий абсолютное совпадение с эталонными библиотеками Scikit-Learn по метрикам ($R^2 = 0.8230$, $MSE = 1.9954$).
2. Экспериментально доказано, что выбор темпа обучения η критически влияет на скорость оптимизации: на стандартизованных данных при $\eta = 0.25$ алгоритм BGD находит глобальный минимум всего за 27 итераций.
3. Сопоставление сходимости выявило преимущества каждого метода: BGD сходится по монотонной траектории за меньшее число итераций ($\mathcal{O}(Nm)$ на шаг), тогда как SGD за счет элементарной сложности шага ($\mathcal{O}(m)$) достигает окрестности решения за долю эпохи (увидев лишь 20% объектов).
4. Исследование регуляризационных путей для Варианта 2 наглядно подтвердило эффект разреживания (Sparsity) L_1-регуляризации Lasso: при росте λ первыми обнуляются статистически наименее значимые признаки (`Physical_Activity`), а дольше всех сохраняется наиболее влиятельный признак (`Attendance`).